

Arquitectura del Proyecto

Proyecto ETL UTVT — Carga de Ventas (SSIS + SQL Server)

1. Visión general

El proyecto implementa un proceso de Extracción, Transformación y Carga (ETL) que toma información de clientes, productos y ventas desde archivos de texto plano (CSV) y la deposita en un Data Warehouse dimensional llamado **DWUTVTVentas**, alojado en SQL Server. El proceso se orquesta mediante un único paquete de SQL Server Integration Services (SSIS), **CargaVentas.dtsx**, desarrollado en Visual Studio.

2. Componentes de la arquitectura

Capa	Componente	Descripción
Origen	3 archivos CSV	Clientes (1000), Productos (500), Ventas (5000). Codificación Windows-1252.
ETL	Paquete SSIS	CargaVentas.dtsx: control flow + tres data flows.
Destino	Data Warehouse	DWUTVTVentas: dimensiones, hechos y bitácoras.
Versionado	Repositorio Git	GitHub, con ramas, Pull Requests y releases.

3. Modelo dimensional

El Data Warehouse sigue un esquema estrella: una tabla de hechos central (**FactVentas**) rodeada de dos dimensiones (**DimCliente** y **DimProducto**). Cada dimensión usa una clave subrogada (surrogate key) autoincremental como llave primaria, y conserva el identificador de origen con un índice único que garantiza la idempotencia del proceso.

Tabla	Tipo	Filas cargadas	Llave
DimCliente	Dimensión	850	IdClienteSK (PK), IdClienteOrigen (UNIQUE)
DimProducto	Dimensión	395	IdProductoSK (PK), IdProductoOrigen (UNIQUE)
FactVentas	Hechos	3264	IdVentaSK (PK), IdVentaOrigen (UNIQUE)
LogErrores	Bitácora	1663	IdError (PK)
LogProceso	Bitácora	1 por corrida	IdProceso (PK)
CategoriaValida	Catálogo	8	Categoria (PK)

4. Flujo de control (orquestración)

El control flow ejecuta las tareas en el siguiente orden: (1) registrar inicio del proceso; (2) validar la existencia de los tres archivos; (3) contenedor de secuencia con los tres data flows en orden Clientes → Productos → Ventas; (4) registrar estadísticas finales; (5) mover los archivos procesados; (6)

comprimir los archivos en un ZIP con marca de tiempo.

El orden Clientes → Productos → Ventas es obligatorio: el flujo de ventas usa búsquedas (Lookup) contra DimCliente y DimProducto, que deben estar pobladas antes de que ventas se ejecute.

5. Patrón de los data flows

Cada data flow sigue el patrón: origen de archivo plano → conteo de leídos → deduplicación → limpieza → conversión de tipos → validaciones (Conditional Split) → búsquedas (Lookup, solo en ventas) → conteo de insertados → destino. Las filas rechazadas se derivan por ramas de error, se unifican con Union All y se envían simultáneamente a la tabla LogErrores y a un archivo CSV de errores (mediante un componente Multicast).

6. Registro y trazabilidad

El proceso registra su actividad en dos bitácoras. **LogErrores** guarda cada fila rechazada con su motivo, el flujo de origen, el archivo y una referencia de la fila. **LogProceso** registra cada ejecución con los totales de filas leídas (6500), insertadas (4509) y rechazadas (1663), la duración y un estatus final que puede ser EXITOSO o COMPLETADO CON ERRORES.